

MSR 2012 @ ICSE

目錄

- Mining Software Repository 2012 @ ICSE
 - MSR(MicroSoft Research) talk @ MSR(Mining Software Repositories)
 - Towards Improving BTS with Game Mechanisms
 - GHTorrent
 - Topic Mining
 - SeCold
 - The evolution of software
 - Do Faster Releases Imporve Software Quality?
 - Security vs Performance Bugs in Firefox
 - 一些感想
 - 基於自然語義分析的commit分割
 - 關於這次發表中大家用的slides系統
 - 微軟是個腹黑娘！

Mining Software Repository 2012 @ ICSE

參加了今年的MSR，會場在University of Zurich。一大早來到大學，註冊有點小插曲，顯然瑞士人搞不清楚中國人的名字，3個楊（Yang）姓的中國人的名牌被搞錯了。然後堀田學長的所屬被寫作了“Japan, Japan”，成為了全日本的代表。

MSR(MicroSoft Research) talk @ MSR(Mining Software Repositories)

首先是來自微軟亞洲研究院（MicroSoft Research @ Asia, MSR Asia）的Keynotes，於是就變成了MSR在MSR的演講。MSR的張冬梅（Dongmei Zhang）女士的演講分為關於Software Analysis和XIAO的兩部分。XIAO是MSRA開發的Code Clone Detector，似乎我要給井上研做的就是這個。想更多瞭解Xiao的細節，不過張女士演講結束的時候的鼓掌導致了話筒的小故障。

Towards Improving BTS with Game Mechanisms

感覺這篇的內容基本上就是關於

<http://www.joelonsoftware.com/items/2008/09/15.html>

這裏寫到的東西，然後說同樣的理論是否可以用於Issue Tracking之類的事情上。個人感覺這個意義不大，stackoverflow之所以成功是因為它把開源社區本身就具有的名譽體系具現化了，本着大家都喜歡被別人奉為大牛的心態，就如同wikipedia一樣。同樣的理論如果用於公司內部的Issue Tracking系統上，會得到完全不同的東西吧。就像MSDN的組織方式雖然和wikipedia是一樣的，但是在MSDN裏找信息的感覺和在

wikipedia完全不一樣。個人不太看好這個方向。

GHTorrent

這篇的slide在這裏可以看
到：<http://www.slideshare.net/gousiosg/ghtorrent-githubs-data-from-a-firehose-13184524>

Data exporter for github. Github的主要數據，代碼，已經可以通過git接口獲得了，wiki是git的形式保存的。所以這個項目的目的就是暴露別的數據，主要是issue tracking, code comments，這種。代碼訪問github api，然後用分佈式實現以克服api的限制，然後提供torrents形式的history下載。github api獲得的json數據以bson的形式保存在MongoDB裏，解析過的有了Schema之後的數據保存在MySQL裏並可以導出SQL。

個人的想法，覺得數據如果能夠更統一，全部存在Git裏或許更好，像Wiki一樣。同樣是要暴露全部歷史記錄的目的，用Torrent自己實現的歷史遠不如用Git的接口實現的歷史記錄方便吧，git blame之類的也更方便追蹤code comment之類的作者信息。當然對git的raw data直接讀寫，需要對git的內部原理有足夠的理解，或許只有github的人有這種能力了。

Topic Mining

用得兩個參數，DE和AIC，完全不能理解，過後研究。實驗針對了Firefox, Mylyn, Eclipse三個軟件。試圖從Repo中分析源代碼的identifier和comments，找到topic和bug之間的關係，比如怎樣的topic更容易導致bug。得出的結論似乎也很有趣，只是說核心功能被報告的bug更多，但是不知道原因。這只能表示核心功能受到更多關注和更多測試吧，並不能說明核心功能就容易產生bug。

不過這個的Slide做得很漂亮，很容易理解。

A linked data platform for mining software repositories

沒聽懂這個項目的目的。

The evolution of software

第二天的Keynotes，關於將Social Media和Software Development相結合的想法。或許就是Github賴以成功的基礎。講到代碼中的comment, Tags, uBlog, blog之類 的social的特性和IDE的融合的趨勢。

Do Faster Releases Improve Software Quality?

使用Firefox作為例子。

結論是快速發佈導致bug更多，更容易crash，但是bug更快得到修復，並且用戶 更快轉向新的發佈。

Security vs Performance Bugs in Firefox

Performance bugs are regression, blocks release.

一些感想

基於自然語義分析的commit分割

經常工具（比如git）的使用者並沒有按照工具設計者的意圖使用工具，這給MSR 帶來很多困難。舉個例子，git有非常完美的branch系統，通常期望git的使用者 能夠在一次commit裏commit一個功能，比如一個bug的修復，或者一個feature的 添加，但是事實上經常有很多邏輯上的commit被合併在一個裏面了。

或許這不是使用者的錯，而是工具仍然不夠人性的表現。或許我們可以自動把 一次的commit按照語義分割成多個。

分割之後，可以更容易地把issue和commit關聯，也更容易組織更多的研究。

關於這次發表中大家用的slides系統

題目爲``Incorporating Version Histories in Information Retrieval Based Bug Localization"的人用的slide是beamer的。公式很多，overlay很多，列表 很多，圖片很少，典型的beamer做出的slide。思維導圖用得很不錯。今天一天 有至少3個slide是用beamer做的。

題目爲``Towards Improving Bug Tracking Systems with Game Mechanisms" 的人用了prezi，圖片很多，過度很多。但是比如沒有頁號沒有頁眉頁腳，正式 會議的場合不太方便。

至少有六個以上用了Apple Keynotes，Keynotes做出來的東西真的和Powerpoint 做出來的很難區別，其中兩個人用了初始的主題所以才看出來。

剩下的自然是PPT。MSRA的張女士做的雖然是PPT，倒是有很多beamer的感覺，比如頁眉頁腳和overlay的用法。這些如果都是PPT做出來的，會多很多額外的人力吧。

值得一提的是有一個題目爲``Green Mining: A Methodology of Relating Software Change to Power Consumption"的人的slide全是``劣質"的手繪漫畫，效果意外地好，很低碳很環保很綠色很可愛。具體效果可以參考下面的動畫，雖然 現場看到的不是一個版本：

<http://softwareprocess.es/a/greenmining-presentation-at-queens-20120522.ogv>

微軟是個腹黑娘！

嘛雖然這也不是什麼新聞了。MSR2012的Mining Challenge的贊助商是微軟，管理 組織者來自微軟研究院，獎品是Xbox和Kinect。然後今年的題目是：

Mining Android Bug

我看到了微軟滿滿的怨氣……